AI 시대의 지역 데이터와 디지털 아카이브

검색하는 아카이브에서 질문하는 아카이브로

RAG기반 조선왕조실록 AI챗봇 설계 연구 사례

Searchable to Askable Archive :
RAG-based Annals of the Joseon Dynasty AI chat-bot Architecture

국립부경대학교 해양인문학연구소 전임연구원
김근하

발표자료와 Ask Sillok

발표자료

littlekg87.github.io/lecture/Asksillok_presentation

Ask Sillok

beta.asksillok.com

검색하는 사료에서
질문하는 사료로

평문 질의

태조는 평양에 성을 쌓게 했는가?

관련 기사 · 태조 2년 1월 6일

도당에 명하여 평양에 성을 쌓도록 하다

命都評議使司, 城平壤。

실록 원문 ↗

키워드 검색으로 돌아가기 ↶ 처음부터 다시 보기 ↶

검색 방식의 차이를 보여주는 개념 예시

지역의 기록, 누구의 언어로 찾는가?

전문가

“강릉 · 읍성 · 축성”

지명과 전문 용어로 정확하게 검색

일반 이용자

“우리 동네 성벽은 왜 세웠을까?”

궁금한 것은 있지만 검색어는 낯설다

외국인 이용자

“Why was the old wall in Gangneung built?”

한국어 지명과 자료의 언어가 낯설다

키워드 중심 검색 자료의 용어를 아는 사람에게 유용하지만, 처음 찾는 사람에게는 문턱이 높다.

일상 언어·다국어 질문 AI가 질문의 의미를 지명·주제·기록에 연결

지역 아카이브 문헌 · 사진 · 구술 기록

검색어를 몰라도, 자신의 언어로 지역의 기록에 닿을 수 있도록.

지역 아카이브 활용 구상 · 질문은 예시이며, 다국어 검색의 정확도는 별도 검증이 필요합니다.

RAG

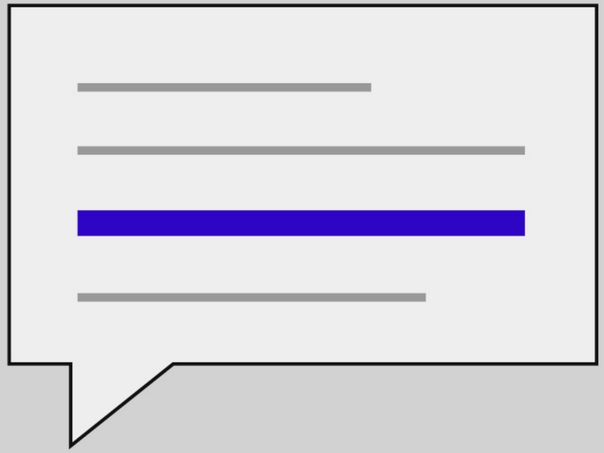
Retrieval-Augmented
Generation

특정한 근거에 기반해 답변을 생성한다



특정한 자료

자료 준비 과정 보기 +



그 자료에 근거한 답변

검색·답변 과정 보기 +

1

DB 구축

사료를 질문할 수 있는 데이터로

시작하기 ↓

사료에서 벡터 DB까지,
단계마다 더한 설계.

일반적인 구축 흐름



청킹

→



임베딩

→



벡터 DB 구축

Ask Sillok의 구축 과정 접기 ↑

01

XML로 구조화

기사의 구조를 보존한 뒤
본문과 메타데이터를 분리

같은 ID로 두 아카이브 연결

02

인코더 직접 파인튜닝

한글 제목과 한문 본문의
대응을 학습

사료에 맞춘 인코더로 벡터화

03

두 형태의 벡터 저장

기본 모델의 벡터
파인튜닝 모델의 벡터

같은 청크 ID로 연결하여 비교

사료의 구조를 보존하고, 인코더를 학습하고, 두 벡터를 비교한다

조선왕조실록 기사 본문

조선왕조실록 태조실록

태조 2년 1월 6일

도당에 명하여 평양에 성을 쌓도록 하다

○壬子/命都評議使司, 城平壤。

도평의사사에 명하여 평양에 성을 쌓게 하였다.

분류 군사 · 관방(關防)

기사 열람 화면 재구성 실제 기사 열기 ↗ XML로 변환하기 →

조선왕조실록의 XML 형식 데이터

ID | 메타데이터 | 본문 | 전체

```
<level5 id="waa_10201006_001">
    <front><biblioData type="T">
        <mainTitle>도당에 명하여 평양에 성을 쌓도록 하다
        </mainTitle>
        <dateOccured date="1393-01-06L0" type="서기"/>
        <subjectClass>군사-관방(關防)</subjectClass>
    </biblioData></front>
    <text><content><paragraph>
        o壬子/命都評議使司, 城<index type="지명">平壤
        </index>。
    </paragraph></content></text>
</level5>
```

선택한 영역

하나의 기사

ID · 메타데이터 · 본문 영역을 선택하면 해당 부분을 확인할 수 있습니다.

← 기사로 보기

실제 XML 발췌 · 일부 생략

XML 구조와 출처 +

두 아카이브로 분리하기 →

같은 ID로 연결된 두 아카이브

TEXT ARCHIVE

본문 아카이브

ID waa_10201006_001

○壬子/命都評議使司,
城平壤。

학습·검색용 텍스트

같은 ID

METADATA ARCHIVE

메타데이터 아카이브

ID waa_10201006_001

제목	도당에 명하여 평양에 성을 쌓도록 하다
왕대 · 날짜	태조 · 1393. 01. 06.
주제	군사 · 관방
출처	실록 원문 링크

본문 ← 같은 ID → 메타데이터 검색할 때 결합하고, 원문으로 돌아간다

← XML로 모으기

제목–본문 대응은 공통 ID로 연결해 학습에 사용한다

설명과 출처 +

기사 임베딩하기 →

기사를 숫자로 바꾸다 — 임베딩

모델에 들어가는 기사

waa_10201006_001

도당에 명하여 평양에 성을 쌓도록 하다

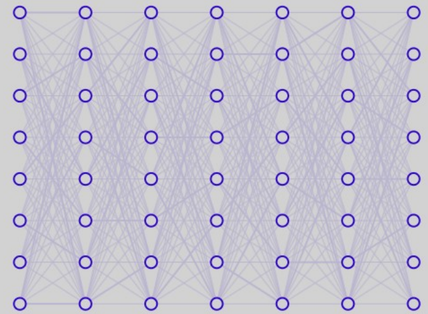
○壬子/命都評議使司, 城平壤。

한글 제목 + 한문 본문

→

인코더

임베딩 모델(LLM)



학습된 가중치로 변환

→

기사의 벡터

waa_10201006_001

1	-0.00061
2	-0.03906
3	-0.00476
4	0.02991
⋮	⋮



2,560차원의 숫자 배열

파인튜닝 — 학습으로 가중치가 달라진다

순전파 → 손실 계산 ← 역전파 가중치 갱신

데이터 학습셋

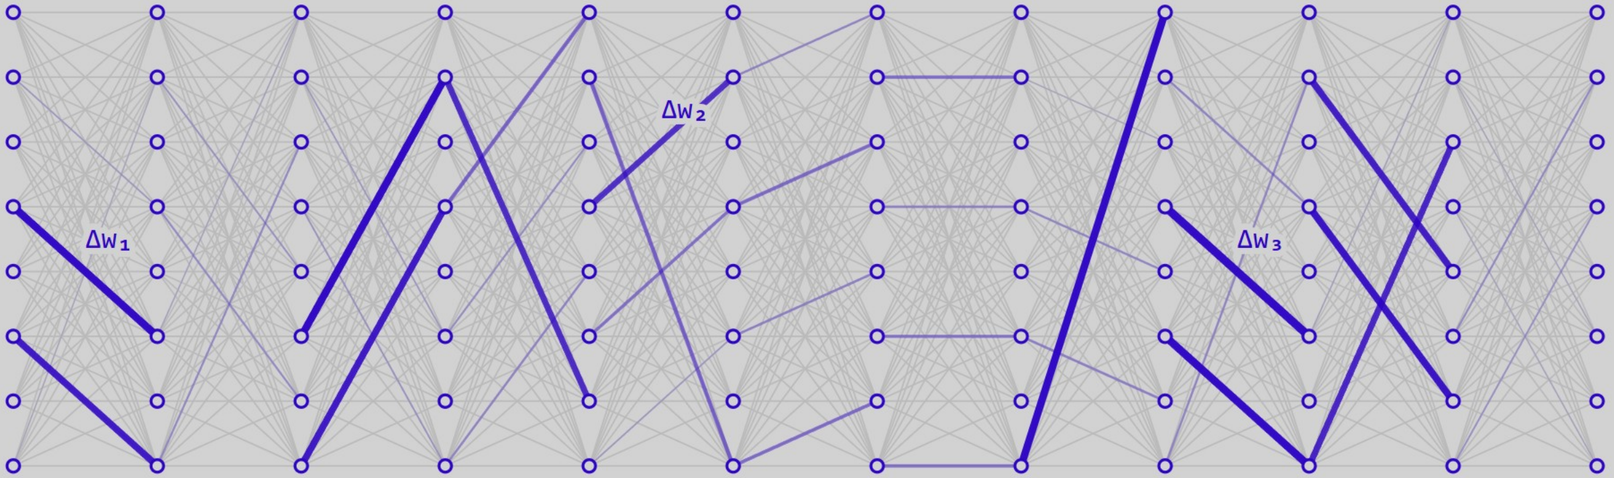
한글 제목

도당에 명하여 평양에 성을 쌓도록 하다

↕ 같은 기사

한문 본문

命都評議使司, 城平壤。



임베딩의 거리



같은 기사의 두 언어를 가깝게 표현

손실: 학습 목표와의 차이

보정값 ΔW₁ 0.0000 → -0.0271

보정값 ΔW₂ 0.0000 → +0.0203

보정값 ΔW₃ 0.0000 → -0.0297

회색 연결은 고정 · 키컬러 연결과 숫자는 학습에 따라 갱신

학습 후 비교 상태 | 학습 전으로 ↶ | 학습 3 / 3 완료 · 보정값 유지

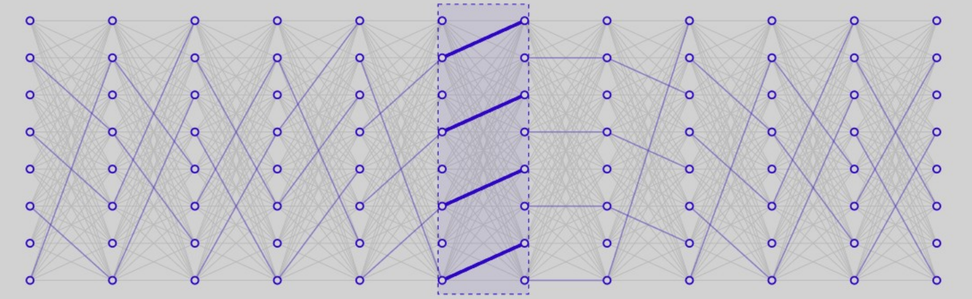
한글 제목–한문 본문 쌍으로 학습하는 LoRA 개념도 · 층 수·신호·보정값·거리 변화는 설명용 예시입니다.

LoRA · Low-Rank Adaptation

LoRA 기법

기존 가중치는 고정하고, 옆에 붙인 어댑터만 학습

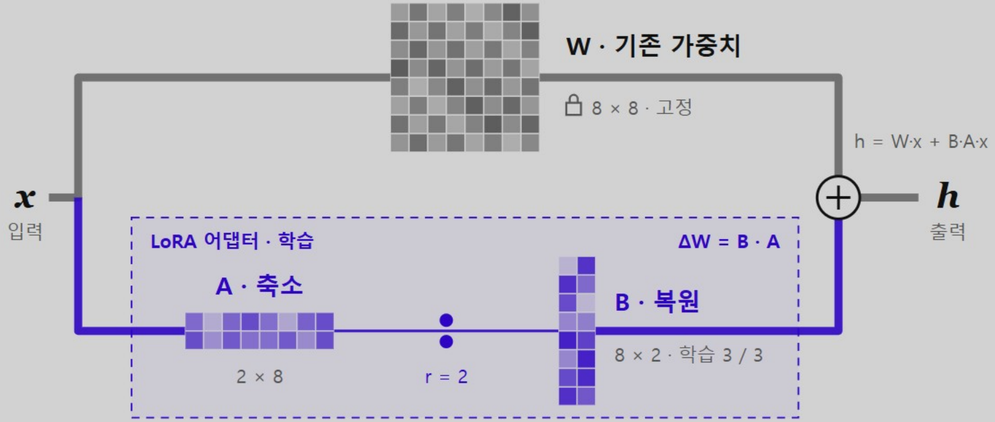
같은 신경망, 다른 학습 방식



01 02 03 04 05 **06** 07 08 09 10 11

연결 구간을 선택하면 그 구간의 W와 어댑터를 확대합니다.

선택한 연결 구간 6



W의 숫자 64개는 그대로 두고, **A·B의 32개만 학습한다.**

크기가 커지면 차이도 커진다. 1,024 × 1,024 = 1,048,576개 대신, r = 8이면 16,384개.

전체 파인튜닝 기존 W 자체를 학습

LoRA **W는 고정 · 어댑터 A·B만 학습 (ΔW = B·A)**

더보기 ↗

다시 학습해 보기 ↻ 처음으로 ↶

학습 완료 · W는 그대로, 어댑터를 더한 출력이 달라짐

파인튜닝 장면과 같은 신경망 개념도 · 연결 구간은 실제 Transformer 층과 일대일 대응하지 않음 · 수치와 크기(8 × 8, r = 2)는 설명용

실록은 이렇게 저장된다

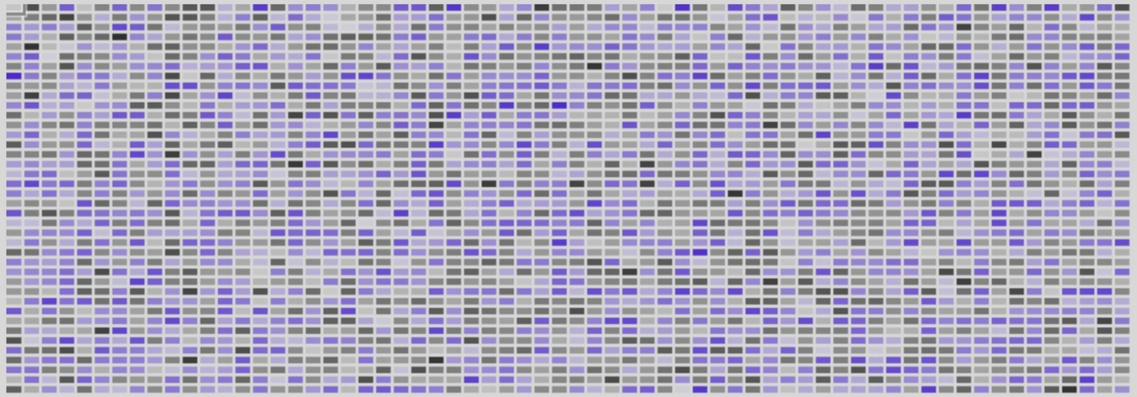
태실·신도 지도 | 연복사 탑 | **평양 축성** | 인일 조하 | 녹봉 지급

도당에 명하여 평양에 성을 쌓도록 하다

2,560차원 · 같은 위치와 색 척도로 비교

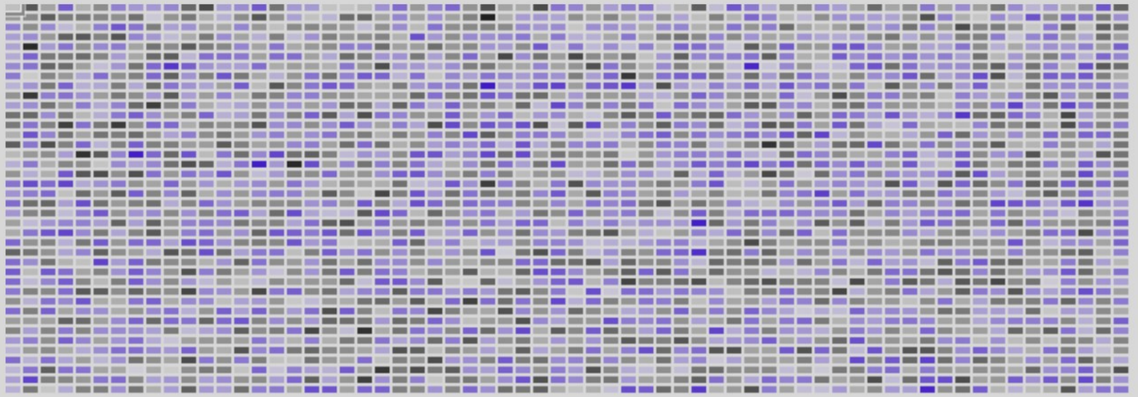
− 0 +

기본 모델



-0.00013732910156250

파인튜닝 모델



-0.00060653686523437

차원 1 / 2,560

실제 저장값 5건 · 같은 칸을 가리키면 두 모델의 값을 함께 확인 · 색 차이는 검색 성능을 뜻하지 않습니다.

▶ 선택한 기사 원문 보기

▶ 데이터와 표시 방식

2

검색

질문에서 근거가 있는 답변으로

시작하기 ↓

질문에서 답변까지,
네 단계의 정교한 프로세스로.

일반적인 검색·답변 흐름



Ask Sillok의 검색 과정 접기 ↑

01

질문 분리

질문 벡터 + 메타데이터

02

유사도·조건 비교

벡터 유사도 + 조건 일치

03

후보 선정·가점

가까운 후보 → 일치 조건 가점

04

답변·출처 연결

근거로 답변 + 실제 기사 링크

질문을 나누고 → 비교하고 → 순위를 정하고 → 근거와 함께 답한다

벡터 유사도 + 메타데이터 일치 기반 재정렬

Hybrid Retrieval · Re-ranking

STEP 01 — 03 · 두 갈래의 검색, 하나의 순위

질문을 나누고, 비교하고, 순위를 정하다

01 질문 처리

질문

태조는 평양에 성을 쌓게 했는가?

본문 데이터 검색

질문 전체를 임베딩

파인튜닝 인코더 → 질문 벡터

`[0.02, -0.04, 0.13, 0.08, -0.11, 0.06, …]`

메타데이터 검색

질문 속 조건만 추출

인물	지명	주제
태조	平壤	군사·관방

02 각각 검색

벡터 유사도로 후보 선정

코사인 유사도 · 높을수록 가까움

A	태조 · 한양 축성	0.92
B	세종 · 평양 성 보수	0.90
C	태조 · 평양 축성	0.88

유사도 상위 후보 A · B · C

D(0.52) 제외

질문 조건이 맞으면 항목별 가점

	인물 일치 +0.05 (태조)	지명 일치 +0.05 (平壤)	주제 일치 +0.05 (군사·관방)
A	+0.05	—	+0.05
B	—	+0.05	+0.05
C	+0.05	+0.05	+0.05

메타데이터 가점 합계

A	B	C
+0.10	+0.10	+0.15

03 결합·최종 순위

결합

벡터 유사도 + **메타데이터 가점**

		벡터		가점
1위 C	1.03	0.88	+	0.15
2위 A	1.02	0.92	+	0.10
3위 B	1.00	0.90	+	0.10

C : 3위 → **1위**

질문의 세 조건 모두 일치

전체 흐름 | 본문 검색 | 메타데이터 검색 | 결합·최종 순위

기사·벡터·점수는 설명용 예시 · 인물·지명·주제 일치 시 각각 +0.05 (실제 운영 가중치 아님) · 합산 점수는 1을 넘을 수 있습니다.

STEP 04 · 답변 생성과 출처 연결

답변의 근거에는 실제 실록 기사를 연결한다

질문

태조는 평양에 성을 쌓게 했는가?

→

근거 · 선정된 기사

태조 2년 · 1393년 1월 6일

도당에 명하여 평양에 성을 쌓도록 하다

○壬子/命都評議使司, 城平壤。

→

LLM

근거로 답변 생성

모델 정보 ↗

→

사료에 근거한 답변

그렇다. 태조 2년(1393) 1월 6일 기사에 따르면, 태조는 도평의사사에 명하여 **평양에 성을 쌓게 했다.** [1]

↖ 인용 번호를 누르면 실제 기사로

답변 생성 다시 보기 ↻ 처음으로 ↻

실제 태조실록 기사에 근거한 시연용 답변 · 실시간 생성 결과가 아닙니다.

이 인문학 프로젝트는 NPU와 AWS에서 작동한다

NPU 가속 임베딩 · AWS 기반 검색 파이프라인

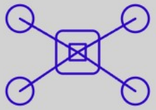


연구 인터페이스

React

연구자의 질문이 들어오는 화면

→

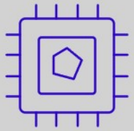


클라우드 오케스트레이션

FastAPI on AWS Lambda

서버리스 API로 검색 과정을 조정

→



임베딩 연산

Qwen3 on NPU

실록 특화 임베딩 생성

→



벡터 검색

AWS S3 Vectors

벡터의 저장과 검색

→



근거 + 답변

S3 Store + DeepSeek

원문 결합과 답변 생성

임베딩 아카이브 **Qwen3-Embedding-4B + LoRA** 2,560차원 · cosine

운영 구성: 한연포럼 발표자료 23페이지 기준 · 모델·차원: 제공된 아카이브 manifest 기준

더보기 ↗

마무리 / 질문하는 아카이브

Ask Sillok

검색이 아니라
질문에 답하는 아카이브

Ask Sillok 열기 ↗

외부 서비스 · 네트워크 연결 필요



김근하 — 국립부경대학교
김병준 — 한국학중앙연구원
우동현 — KAIST
박정희 — 동국대
이시헌 — 한국학중앙연구원

Ask Sillok 연구팀

서비스와 이 시안 +

지역 아카이브와 AI

지역의 기록을
누구나 질문할 수 있는 지식으로

주민은 마을의 기억을 찾고, 학생은 지역의 역사를 배우고,
방문객은 자신의 언어로 장소의 이야기를 만납니다.

AI는 질문과 기록을 연결하고,
아카이브는 출처와 맥락으로 답변을 뒷받침합니다.

경청해주셔서 감사합니다

발표자료

littlekg87.github.io/lecture/Asksillok_presentation

Ask Sillok

beta.asksillok.com

포트폴리오

kunslab.com

부록

모델 비교와 평가

모델 비교 · 전문가 평가 · 연구 결과

시작하기 ↓

Qwen3 Embedding · 0.6B / 4B / 8B

세 모델을 직접 파인튜닝하고,
여섯 모델의 성능을 비교했다.

	Qwen3 Embedding 0.6B	Qwen3 Embedding 4B	Qwen3 Embedding 8B
기본 모델	기본 모델	기본 모델	기본 모델
파인튜닝	↓	↓	↓
직접 만든 모델	Qwen3 Embedding **0.6B LoRA** ✓ 파인튜닝 모델	Qwen3 Embedding **4B LoRA** ✓ 파인튜닝 모델	Qwen3 Embedding **8B LoRA** ✓ 파인튜닝 모델

전체 비교 펼쳐짐 처음부터 ↺

기본 3개와 직접 파인튜닝한 3개, 총 6개 모델의 성능을 비교했다.

직접 파인튜닝한 모델 **3** 개 → 기본 3개 + 파인튜닝 3개 **6** 개 모델 비교

더보기 ↗

EXPERT EVALUATION · 전문가 블라인드 평가

검색된 사료의 관련성은,
역사연구자가 직접 평가했다.

01 연구 질문 →

시대 고유 개념 | 현대어–사료 용어 차이 | 복합 조건 | 고유명사 | 표면 일치 대조군

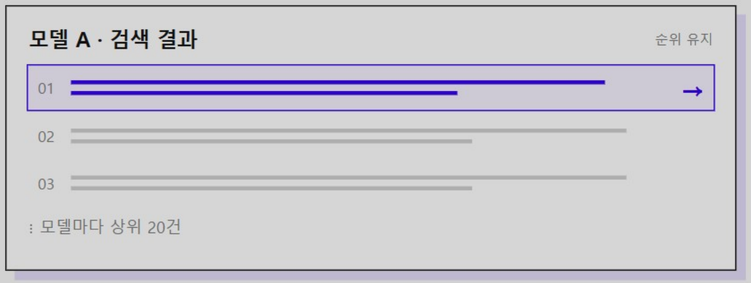
사화의 원인과 결과는 무엇인가?

조선사 연구자 2인이 질문 설계

02 익명 검색 결과 →

모델 이름·거리 점수는 가리고

A | B | C | D



A–D는 평가자·질문마다 무작위 배정

03 전문가의 판단

모델 A · 1위 사료

이 질문에 관련되는 사료인가?

0	1	2
관련 없음	부분 관련	명확한 관련

시연 선택: 2점 · 실제 전문가 평정값 아님

실제 연구에서는 10명이 각각 독립적으로 평정

50 연구 질문 × **4** 모델 × **20** 상위 사료 × **10** 역사연구자 = **40,000** 건의 평정

더보기 ↗

검색 목록·선택 점수는 절차 시연용 도식 · 실제 검색 결과·전문가 평정값 아님 · IJKH 원고 §3.2

연구 결과와 시사점

기계의 성능 향상이,
연구의 유용성을 보장하지는 않는다.

벤치마크 평가

성능은 좋아졌다.

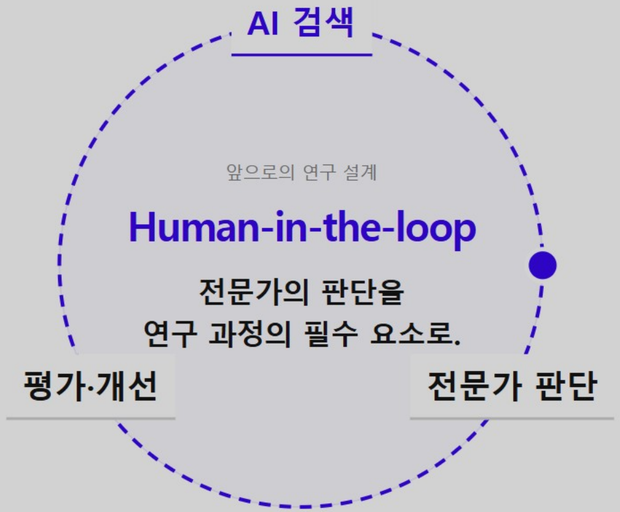
제목으로 짝인 본문을 찾는 능력은 향상

≠

전문가 평가

개선은 고르지 않았다.

모델·질문 유형에 따라 효과가 달랐고,
일부에서는 검색 성능이 낮아졌다.



AI가 넓은 자료에서 관련 사료의 후보를 찾는다.

AI는 만능이 아니다. **기술의 발전과 전문가의 판단이 함께 가야 한다.**

IJKH 제출 원고의 결과·논의를 요약 · 아래 순환 구조는 향후 연구 설계의 방향

관련 연구

1. 김근하,「데이터는 어떻게 AI의 답변을 바꾸는가: 세종실록지리지의 데이터 구조화 방식에 따른 RAG 응답 비교 실험」,『한문학논집』72, 2026.

2. 김근하, 김병준, 우동현, 박정희, 이시헌, “Fine-Tuned Embeddings in Historical RAG: Benchmark Performance and Expert Evaluation on the Veritable Records of the Chosŏn Dynasty”, 현재 심사 중.

3. 김근하 외 4인,「편년체 사료의 교차언어 검색을 위한 시스템, 검색 방법 및 색인 구축 방법」, 특허출원, 2025.08.26.

4. 김근하 외 4인,「편년체 사료의 제목과 본문의 대응관계에 기초한 교차언어 인코더 학습방법 및 그 장치」, 특허출원, 2025.08.26.